Техническое задание

База знаний по психиатрии для RAG, умных отчётов и суммаризации · версия 1.0 · 21.10.2026

Цель	Создать проверяемую и версионируемую базу клинических знаний. Система формирует черновики только на основе найденных фактов со ссылками; итоговое решение подтверждает врач.

1. Границы первого релиза

Начать с 8–10 приоритетных групп: депрессивные, тревожные и панические расстройства, ОКР, ПТСР, БАР, расстройства шизофренического спектра, сна, зависимости и суицидальный риск. После измерения качества расширять охват.

Функции базы

- RAG: гибридный поиск, фильтры и точные ссылки на источник.
- Отчёты: симптомы, шкалы, риски, назначения и динамика.
- Суммаризация: краткая сводка без выдуманных сведений.
- Безопасность: отдельные правила для суицидального риска, психоза и тяжёлых нежелательных реакций.

2. Источники

№	Источник	Что извлекаем
1	Клинические рекомендации Минздрава РФ	Диагностика, лечение, мониторинг, маршрутизация
2	ГРЛС и официальные инструкции	МНН, показания, режимы, противопоказания, взаимодействия, НР
3	Росздравнадзор и нормативные документы	Фармаконадзор и обязательные требования
4	Оригинальные материалы шкал	Версия, перевод, вопросы, расчёт, пороги, лицензия
5	Международные руководства	Только дополнение с маркировкой страны и версии

Не использовать	Блоги, форумы и коммерческие карточки препаратов как первичный клинический источник.

3. Какие данные собрать

Набор	Обязательные поля
Источник	ID, организация, URL, тип, версия, даты публикации/проверки, юрисдикция, лицензия, checksum, статус
Состояние	Коды/синонимы, симптомы, критерии, тяжесть, риски, дифдиагностика, коморбидность, красные флаги, маршрут
План ведения	Популяция, условия, цель, шаг, лечение, мониторинг, срок оценки, критерии смены шага
Препарат	МНН, торговые названия, регистрационный ID, показания, режим по инструкции, возраст, противопоказания, взаимодействия, НР, беременность/лактация, мониторинг
Шкала	Название/версия, назначение, валидированный русский источник, лицензия, вопросы, расчёт, пороги
Правило безопасности	Формальное условие, тяжесть, действие/маршрут, решение врача, источник
Eval-сценарий	Входные факты, ожидаемые документы, обязательные пункты, запрещённые утверждения и цитаты

4. Архитектура

- Raw: неизменённые PDF/HTML и контрольные суммы.
- PostgreSQL: реестр, сущности, связи, версии и история проверки; для прототипа допустим SQLite.
- pgvector или Qdrant: поисковый индекс; эмбеддинги строятся при импорте и не входят в поставку.
- Гибридный поиск: семантический + полнотекстовый/BM25 с фильтрами.
- API: возвращает текст, факты, релевантность и координаты источника.

Источник истины	Исходные документы и структурированные записи PostgreSQL. Индекс можно перестроить при смене модели.

5. Формат передачи

knowledge-base/
README.md · data_dictionary.md · changelog.md
raw/{source_id}/source.pdf · sources.jsonl
entities/conditions.jsonl · medications.jsonl · scales.jsonl · recommendations.jsonl
safety_rules.jsonl · chunks.jsonl · eval_cases.jsonl · qa_report.json

Требования: UTF-8; JSONL — один объект на строку; даты ISO 8601; стабильные ID; null для пустых значений; без персональных данных. Каждый факт содержит source_id, страницу/раздел, дату проверки и статус врача.

6. Задание для двух исполнителей

Исполнитель 1

Клинический редактор данных

- Согласовать охват и словарь терминов.
- Собрать официальный реестр источников и права.
- Заполнить состояния, препараты, шкалы, планы и правила.
- Для каждого факта указать источник, страницу и дату.
- Подготовить 40 клинических сценариев.
- Передать высокорисковые пункты врачу-эксперту.

Результат: JSONL-наборы, журнал вопросов и клиническая приёмка.

Исполнитель 2

Инженер данных / RAG

- Утвердить JSON Schema, ID и валидатор.
- Сделать импорт PDF/HTML, OCR, очистку и чанкинг.
- Развернуть PostgreSQL и векторный индекс.
- Сделать гибридный поиск и API с цитатами.
- Проверять схемы, дубликаты, ссылки и версии.
- Запускать eval-набор и сохранять метрики.

Результат: схема БД, импортёр, индексатор, API, инструкция и отчёт качества.

Совместные точки

- Старт: врач утверждает охват, иерархию источников и критические правила.
- После первых 2 состояний: зафиксировать JSONL-схему и чанкинг.
- Еженедельно: разбор новых источников, спорных фактов и ошибок.
- Релиз: клиническая и техническая приёмка одной версии.

7. Приёмка

- 8–10 состояний; ≥15 МНН; 5 шкал; 30 правил; 40 сценариев.
- 100% фактов имеют источник, координаты, версию и статус проверки.
- JSONL валиден; нет повторных ID и фрагментов без источника.
- Recall@5 ≥ 0,85 на согласованных сценариях.
- Каждый клинический тезис сопровождается ссылкой; отсутствие данных указано явно.
- Критические правила проверены врачом и негативными тестами.
- Новая версия источника показывает diff и запускает повторную проверку.

8. Минимальная запись RAG

{"chunk_id":"ru_cr_gad_v1__treatment__003", "source_id":"ru_cr_gad_v1",
"entity_ids":["condition:generalized_anxiety"], "section_path":["Лечение","Фармакотерапия"],
"text":"Нормализованный фрагмент...", "fact_types":["treatment","monitoring"],
"evidence":{"page":42,"section":"5.2"}, "review":{"status":"approved","reviewed_at":"2026-10-21"}}

Официальные ориентиры

- Рубрикатор клинических рекомендаций Минздрава РФ
- Государственный реестр лекарственных средств
- Росздравнадзор: фармаконадзор
- WHO ICD-11
- HL7 FHIR R5

До наполнения Врач утверждает клинический охват и правила безопасности. Для промышленного использования отдельно проверяются лицензии, защита персональных данных и правовой статус.